

山田龍

2020 年 11 月 23 日

## 1 Gauss-Seidel 法

Gauss-Seidel 法と SOR 法の導出については [1] の導出を参考にした。

$$A = D + L + U \quad (1)$$

の順番で対角成分、下三角成分、上三角成分を定義する。解くべき連立方程式は、

$$(D + L + U)\mathbf{x} = \mathbf{b} \quad (2)$$

$$\mathbf{x} = -D^{-1}(L + U)\mathbf{x} + D^{-1}\mathbf{b} \quad (3)$$

ヤコビ法では、以下の漸化式が成立すれば  $\mathbf{x}^{(k)}$  は連立方程式の解である。

$$\mathbf{x}^{(k+1)} = -D^{-1}L\mathbf{x}^{(k)} - D^{-1}U\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \quad (4)$$

Gauss-Seidel 法では、以下の漸化式が成立すれば  $\mathbf{x}^{(k)}$  は連立方程式の解である。

$$\mathbf{x}^{(k+1)} = -D^{-1}L\mathbf{x}^{(k+1)} - D^{-1}U\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \quad (5)$$

$$= -D^{-1}(L + U)\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \quad (6)$$

反復の計算は、

$$(E + D^{-1}L)\mathbf{x}^{(k+1)} = -D^{-1}U\mathbf{x}^{(k)} + D^{-1}\mathbf{b}$$

$$(D + L)D^{-1}\mathbf{x}^{(k+1)} = -D^{-1}U\mathbf{x}^{(k)} + D^{-1}\mathbf{b}$$

$$\mathbf{x}^{(k+1)} = -(D + L)^{-1}U\mathbf{x}^{(k)} + (D + L)^{-1}\mathbf{b}$$

ここで、 $\mathbf{d}^{(k+1)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$  を定義する。

$$\begin{aligned} \mathbf{d}^{(k+1)} &= -[(D + L)^{-1}U + E]\mathbf{x}^{(k)} + (D + L)^{-1}\mathbf{b} \\ &= -[(D + L)^{-1}U - D^{-1}U + D^{-1}U + E]\mathbf{x}^{(k)} \\ &\quad + [(D + L)^{-1} - D^{-1} + D^{-1}]\mathbf{b} \\ &= -[-L(D + L)^{-1}D^{-1}U + D^{-1}U + E]\mathbf{x}^{(k)} \\ &\quad + [-L(D + L)^{-1}D^{-1} + D^{-1}]\mathbf{b} \\ &= -D^{-1}L\mathbf{x}^{(k+1)} - (D^{-1}U + E)\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \end{aligned}$$

更に変形する。

$$\begin{aligned}
(E + D^{-1}L)\mathbf{d}^{(k+1)} &= -D^{-1}L(-D^{-1}U\mathbf{x}^{(k)} + D^{-1}\mathbf{b}) \\
&\quad - (D^{-1}U + E)(-D^{-1}U\mathbf{x}^{(k-1)} + D^{-1}\mathbf{b}) \\
&\quad + (D^{-1} + D^{-1}LD^{-1})\mathbf{b} \\
&= -D^{-1}LD^{-1}U\mathbf{x}^{(k)} - D^{-1}LD^{-1}\mathbf{b} \\
&\quad + (D^{-1}UD^{-1}U + D^{-1}U)\mathbf{x}^{(k-1)} \\
&\quad - (D^{-1}UD^{-1} + D^{-1})\mathbf{b} \\
&\quad + (D^{-1} + D^{-1}LD^{-1})\mathbf{b}
\end{aligned}$$

両辺変形して、

$$\begin{aligned}
D^{-1}(D + L)\mathbf{d}^{(k+1)} &= D^{-1}[-LD^{-1}U\mathbf{x}^{(k)} - LD^{-1}\mathbf{b} \\
&\quad + (UD^{-1}U + U)\mathbf{x}^{(k-1)} \\
&\quad + (-UD^{-1} + LD^{-1})\mathbf{b}] \\
(D + L)\mathbf{d}^{(k+1)} &= -LD^{-1}U\mathbf{x}^{(k)} - LD^{-1}\mathbf{b} \\
&\quad + (UD^{-1}U + U)\mathbf{x}^{(k-1)} \\
&\quad + (-UD^{-1} + LD^{-1})\mathbf{b}
\end{aligned}$$

左辺の係数の逆行列を両辺にかけて、

$$\begin{aligned}
\mathbf{d}^{(k+1)} &= (D + L)^{-1}U[-LD^{-1}\mathbf{x}^{(k)} + (D^{-1}U + E)\mathbf{x}^{(k-1)} - D^{-1}\mathbf{b}] \\
&= (D + L)^{-1}U\mathbf{d}^{(k)}
\end{aligned}$$

よって Gauss-Seidel 法において解が収束する条件は、

$$\|(D + L)^{-1}U\|_2 < 1 \quad (7)$$

反復すべき式は、

$$D\mathbf{x}^{(k+1)} = -L\mathbf{x}^{(k+1)} - U\mathbf{x}^{(k)} + \mathbf{b} \quad (8)$$

$$a_{ii}\mathbf{x}_i^{(k+1)} = -\sum_{j=1}^{i-1} a_{ij}\mathbf{x}_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}\mathbf{x}_j^{(k)} + \mathbf{b}_i \quad (9)$$

## 2 SOR 法

Gauss-Seidel 法において、緩和係数  $\omega$  を持ち込んで改良した解法を SOR 法という。Gauss-Seidel 法の計算式を変形する。

$$(E + D^{-1}L)\mathbf{x}^{(k+1)} = -D^{-1}U\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \quad (10)$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - D^{-1}L\mathbf{x}^{(k+1)} - (D^{-1}U + E)\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \quad (11)$$

SOR 法では緩和係数  $\omega$  を導入する。

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega \left[ -D^{-1}L\mathbf{x}^{(k+1)} - (D^{-1}U + E)\mathbf{x}^{(k)} + D^{-1}\mathbf{b} \right] \quad (12)$$

$$(E + \omega D^{-1}L)\mathbf{x}^{(k+1)} = [E - \omega(D^{-1}U + E)]\mathbf{x}^{(k)} + \omega D^{-1}\mathbf{b} \quad (13)$$

反復すべき式は、

$$D\mathbf{x}^{(k+1)} = D\mathbf{x}^{(k)} + \omega \left[ -L\mathbf{x}^{(k+1)} - (U + D)\mathbf{x}^{(k)} + \mathbf{b} \right] \quad (14)$$

$$D\mathbf{x}^{(k+1)} = -\omega L\mathbf{x}^{(k+1)} + [D - \omega(U + D)]\mathbf{x}^{(k)} + \omega\mathbf{b} \quad (15)$$

成分表示すれば、

$$a_{ii}\mathbf{x}_i^{(k+1)} = -\omega \sum_{j=1}^{i-1} a_{ij}\mathbf{x}_j^{(k+1)} + (1 - \omega)a_{ii}\mathbf{x}_i^{(k)} - \omega \sum_{j=i+1}^n a_{ij}\mathbf{x}_j^{(k)} + \omega\mathbf{b}_i \quad (16)$$

緩和係数は問題に応じて選択される。

### 3 課題 1

$$\begin{pmatrix} 10 & 1 & 4 & 0 \\ 1 & 10 & 5 & -1 \\ 4 & 5 & 10 & 7 \\ 0 & -1 & 7 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 15 \\ 15 \\ 26 \\ 15 \end{pmatrix} \quad (17)$$

$$\begin{pmatrix} 10 & 1 & 4 & 0 \\ 1 & 10 & 5 & -1 \\ 4 & 5 & 10 & 7 \\ 0 & -1 & 7 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 16 \\ 16 \\ 25 \\ 16 \end{pmatrix} \quad (18)$$

の解を Gauss の消去法を用いて求める。

#### 3.1 単精度と倍精度

計算機において実数を表示するためには浮動小数点法が使われる。計算機の内部において 2 進数が使われていたとき、その表現は、以下のように記述できる。

$$\pm(1.a_1a_2\cdots a_m) \times 2^e \quad (19)$$

では、単精度の場合に指数部が 8 ビットであったとしよう。いま、10 進数で 12.5 の数値を浮動小数点表示したいとする。まず符号は + なので符号の部分のビットは 0 である。12.5 は 2 進数表示で  $1.1001 \times 2^3$  と表される。指数部分はバイアス  $128 - 1 = 127$  を使った記法を用いれば、 $(3 + 127)_{10} = (130)_{10} = (10000010)_2$  となる。仮数部は、正規化された 2 進数表示の場合には必ず先頭は 1 になるので、先頭を省略して  $10010 \cdots 0$  となる。図示すれば以下ようになる。

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	...	32
符号	指数部	-	-	-	-	-	-	-	仮数部	-	-	-	-	-	...	-
0	1	0	0	0	0	0	1	0	1	0	0	1	0	0	...	0

numpy の float32、float64 においては、numpy.finfo 関数を使ってそれぞれの仕様を確認することができる。

```
Machine parameters for float32
precision = 6 resolution = 1.0000000e-06
machep = -23 eps = 1.1920929e-07
negexp = -24 epsneg = 5.9604645e-08
minexp = -126 tiny = 1.1754944e-38
maxexp = 128 max = 3.4028235e+38
nexp = 8 min = -max
```

```
Machine parameters for float64
precision = 15 resolution = 1.0000000000000001e-15
machep = -52 eps = 2.2204460492503131e-16
negexp = -53 epsneg = 1.1102230246251565e-16
minexp = -1022 tiny = 2.2250738585072014e-308
maxexp = 1024 max = 1.7976931348623157e+308
nexp = 11 min = -max
```

ここから、単精度では指数部が  $8bit$  で仮数部が  $32 - 1 - 8 = 23bit$  あるので 10 進数では 6 桁の精度、倍精度では指数部が  $11bit$  で仮数部が  $64 - 1 - 11 = 52bit$  あるので 10 進数では 15 桁の精度があることがわかる。

### 3.2 $b = (15, 15, 26, 15)^T$ の場合

Gauss の消去法を使って  $A\mathbf{x} = \mathbf{b}$  の解  $\mathbf{x}$  を求めた。単精度では、

```
x: [1. 1.0000001 0.9999999 1. ]
A * x: [14.99999964 15.0000006 25.9999994 14.99999905]
```

倍精度では、

```
x: [1. 1. 1. 1.]
A * x: [15. 15. 26. 15.]
```

比較すると、単精度の場合には 7 桁目以降で誤差が生じている。

### 3.3 $b = (16, 16, 25, 16)^T$ の場合

Gauss の消去法を使って  $A\mathbf{x} = \mathbf{b}$  の解  $\mathbf{x}$  を求めた。単精度では、

```
x: [ 832.18555 1324.2953 -2407.5376 2021.451 ]
A * x: [16.00036621 15.99938965 25. 16.00097656]
```

倍精度では、

```
x: [ 832. 1324. -2407. 2021.]
A * x: [16. 16. 25. 16.]
```

比較すると、4 桁目以降に誤差が生じている。これは、

## 4 課題 2

$$\begin{pmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 0 & -1 \\ 0 & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad (20)$$

の解を SOR 法を用いて求める。

#### 4.1 解と反復係数

### 5 プログラム

ソースコードを添付しますが、全て <https://github.com/tychy/NumericalAnalysisPlayground> にあります。各関数のテストもついています。

ソースコード 1 gauss の消去法

```
import numpy as np

def scale(A, x):
    scale_ls = np.zeros_like(x)
    for i in range(A.shape[0]):
        max_idx = 0
        for j in range(A.shape[0]):
            if np.abs(A[i, j]) > np.abs(A[i, max_idx]):
                max_idx = j
        scale_ls[i] = np.abs(A[i, max_idx])
        x[i] = x[i] / np.abs(A[i, max_idx])
        A[i, :] = A[i, :] / np.abs(A[i, max_idx])
    return scale_ls

def pivot(A, x, idx):
    max_idx = idx
    for i in range(idx, A.shape[0]):
        if A[idx, i] > A[max_idx, i]:
            max_idx = i
    if max_idx != idx:
        buff = np.copy(A[max_idx, :])
        A[max_idx, :] = A[idx, :]
        A[idx, :] = buff
        buffx = x[max_idx]
        x[max_idx] = x[idx]
        x[idx] = buffx
    return

def execute(A, b):
    assert A.shape[0] == A.shape[1], "A must be n * n"
    assert A.shape[0] == b.shape[0], "size of A and b must match"
    print("A:", A)
    print("b:", b)
    L = np.zeros_like(A)
    for i in range(A.shape[0]):
        L[i, i] = 1
    scale_ls = scale(A, b)
    print("Scaled A:", A)

    pivot(A, b, 0)
    for i in range(1, A.shape[0]):
        pivot(A, b, i)
```

```

        for j in range(i, A.shape[0]):
            coef = A[j][i - 1] / A[i - 1][i - 1]
            A[j, :] = A[j, :] - A[i - 1, :] * coef
            b[j] = b[j] - b[i - 1] * coef
            L[j, i - 1] = coef
x = np.zeros_like(b)
print("L:", L)
for i in range(A.shape[0] - 1, -1, -1):
    x[i] += b[i]
    for j in range(i, A.shape[0] - 1):
        x[i] -= A[i][j + 1] * x[j + 1]
    x[i] /= A[i][i]
print("x:", x)
for i in range(A.shape[0]):
    A[i, :] = A[i, :] * scale_ls[i]

return x, L, A

def single(A, b):
    print("-----single-----")
    A_copy = np.copy(A).astype(np.float32)
    b_copy = np.copy(b).astype(np.float32)
    fi32 = np.finfo(np.float32)
    print(fi32)
    x, L, U = execute(A_copy, b_copy)
    print("A_*_x:", A @ x.T)
    print("-----END-----")

def double(A, b):
    print("double")

    A_copy = np.copy(A).astype(np.float64)
    b_copy = np.copy(b).astype(np.float64)
    fi64 = np.finfo(np.float64)
    print(fi64)
    x, L, U = execute(A_copy, b_copy)
    print("A_*_x:", A @ x.T)
    print("-----END-----")

if __name__ == "__main__":
    A = np.array(
        [
            [10.0, 1.0, 4.0, 0.0],
            [1.0, 10.0, 5.0, -1.0],
            [4.0, 5.0, 10.0, 7.0],
            [0.0, -1.0, 7.0, 9.0],
        ],
    )
    b = np.array([15.0, 15.0, 26.0, 15.0])
    c = np.array([16.0, 16.0, 25.0, 16.0])

    single(A, b)
    double(A, b)
    single(A, c)

```

```
double(A, c)
```

ソースコード 2 スクリプトファイル名

## 参考文献

- [1] 石原卓水島二郎. 理工学のための数値計算法. 2002.